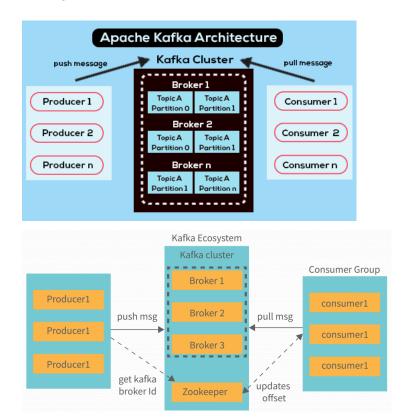
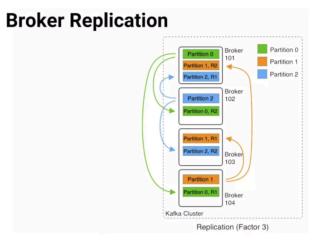
# Conceptos



Zookeeper vigila a los broker (manager). Si un broker se cae, los demás toman esa responsabilidad de realizar las tareas necesarias.

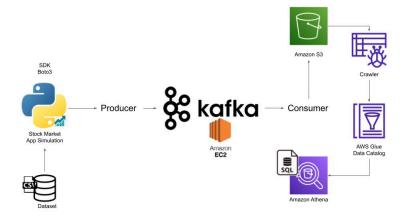




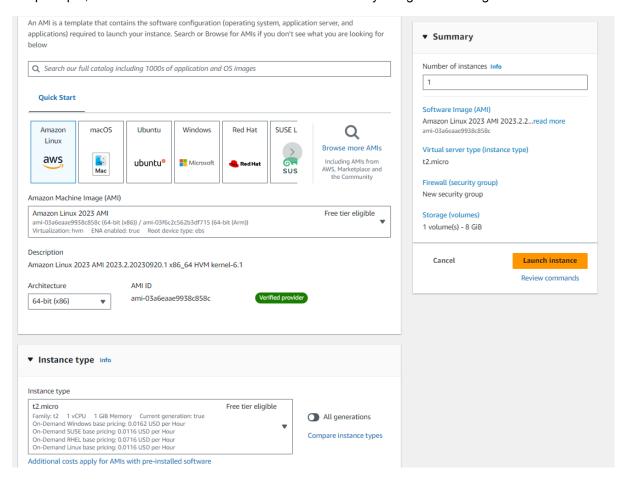
# Lesson Glossary

- Broker (Kafka) A single member server of the Kafka cluster
- Cluster (Kafka) A group of one or more Kafka Brokers working together to satisfy Kafka production and consumption
- Node A single computing instance. May be physical, as in a server in a datacenter, or virtual, as an instance might be in AWS, GCP, or Azure.
- Zookeeper Used by Kafka Brokers to determine which broker is the leader of a given partition and topic, as well as track cluster membership and configuration for Kafka
- Data Partition (Kafka) Kafka topics consist of one or more partitions. A
  partition is a log which provides ordering guarantees for all of the data
  contained within it. Partitions are chosen by hashing key values.

### **Architecture**



En principio, creamos una instancia EC2 con Amazon Linux y la siguiente configuración.



Generamos una key para acceder a la máquina virtual.



Usamos SSH para conectarnos a la máquina.

Inicialmente descargamos la última versión de Kafka para poder usarla en nuestra máguina virtual.

Luego descomprimimos con la ayuda del comando:

```
tar -xvf kafka_2.12-3.3.1.tgz
```

Ahora debemos instalar java dentro de la instancia.

sudo yum install java-1.8.0-openjdk / sudo yum install java-1.8.0-amazon-corretto-devel java -version

En este momento ya podemos correr el zookeeper en una ventana (1) y el servidor de kafka (2) en otra.

- (1) bin/zookeeper-server-start.sh config/zookeeper.properties
- (2)

Incrementamos memoria para nuestro servidor de kafka.

```
export KAFKA HEAP OPTS="-Xmx256M -Xms128M"
```

Para poder conectarnos con nuestra máquina local debemos exponer la dirección IP pública de nuestro EC2.

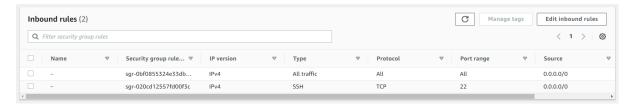
Utilizamos el siguiente comando para ingresar al archivo.

sudo nano config/server.properties

Luego corremos el servidor.

bin/kafka-server-start.sh config/server.properties

Agregamos una nueva regla al security group de nuestra EC2 para poder acceder desde nuestra máquina local.



En este punto, ya podemos crear el **topic** en una nueva ventana de la instancia, usando el siguiente comando.

bin/kafka-topics.sh --create --topic demo\_testing2 --bootstrap-server 174.129.108.126:9092 --replication-factor 1 --partitions 1

```
[ec2-user@ip-172-31-81-89 kafka_2.12-3.5.1]$ bin/kafka-topics.sh --create --topic demo_testing2 --bootstrap-server 107.2 3.252.79:9092 --replication-factor 1 --partitions 1 WARNING: Due to limitations in metric names, topics with a period ('.') or underscore ('_') could collide. To avoid issu es it is best to use either, but not both. Created topic demo_testing2.
```

Luego creamos el **producer** con el siguiente comando.

bin/kafka-console-producer.sh --topic demo testing2 --bootstrap-server 174.129.108.126:9092

En una ventana nueva creamos el consumer.

bin/kafka-console-consumer.sh --topic demo\_testing2 --bootstrap-server 174.129.108.126:9092

## Producer

```
[ec2-user@ip-172-31-81-89 kafka_2.12-3.5.1]$ bin/kafka-console-producer.sh --topic demo_testing2 --bootstrap-server 107.23.252.79:9092 >hello world 
>fvf 
>fbfn 
>hnhnn 
>jijj
```

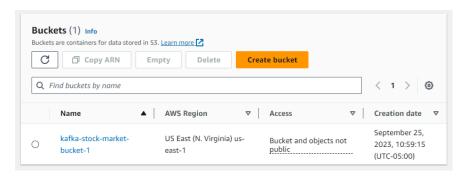
### Consumer

```
[ec2-user@ip-172-31-81-89 kafka_2.12-3.5.1]$ bin/kafka-console-consumer.sh --topic demo_testing2 --bootstrap-server 107.23.252.79:9092
hello world
fvf
fbfn
hnhn
jijij
```

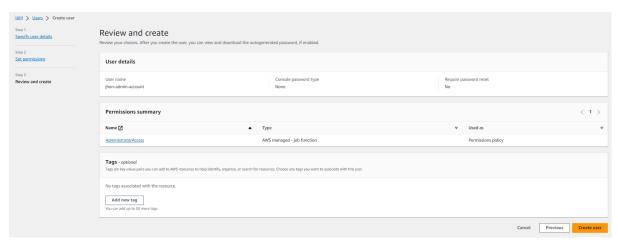
Ahora, usamos nuestro notebook en Python para conectarnos al **producer** y poder enviar mensajes al **consumer**.

Creamos la conexión al consumer en Python y desde ahí podemos ver lo que llega desde el producer.

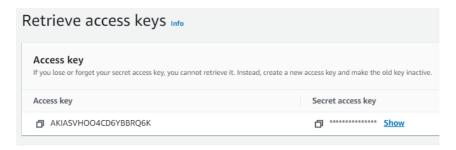
Creamos un bucket en S3.



Debemos crear un user para conectarnos al S3.



Creamos una key dentro del user para poder acceder.



Realizamos esta configuración en nuestra máquina.

```
PS C:\Program Files\Amazon\AWSCLIV2> aws configure AWS Access Key ID [************RQ6K]: AWS Secret Access Key [**************/hX]: Default region name [None]: us-east-1 Default output format [us-east-1]: None
```

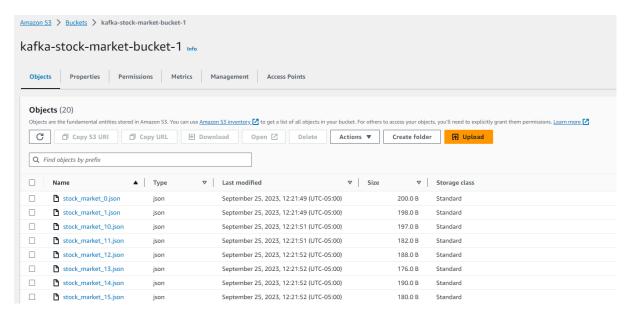
En este punto, ya podemos enviar datos al S3. Lo hacemos de la siguiente forma.

KafkaConsumer - Apuntamos al S3 enviando lo que recibimos en el consumer.

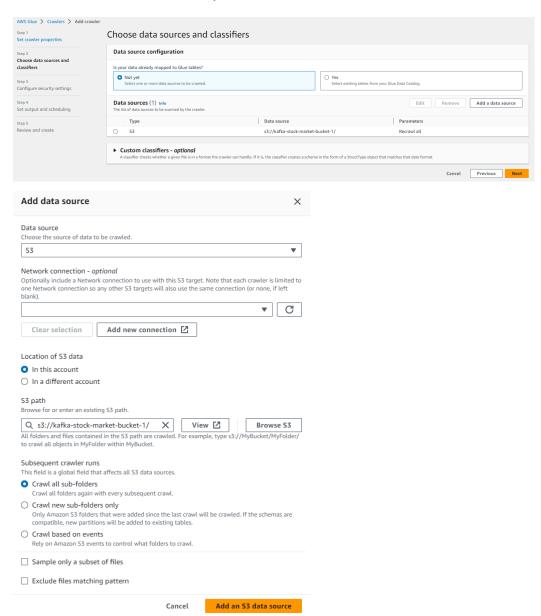
KafkaProducer - Usamos el producer para tomar registros aleatorios del dataset y enviarlos al consumer.

```
while True:
    dick_stock = df.sample(1).to_dict(orient='records')[0]
    producer.send('demo_testing2', value=dick_stock)
```

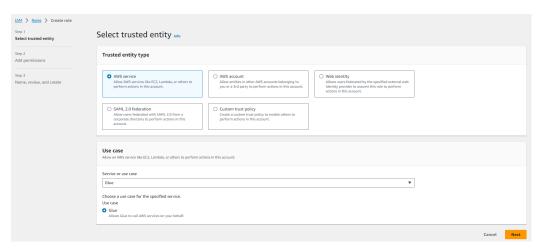
En el bucket quedan cargados los archivos json.



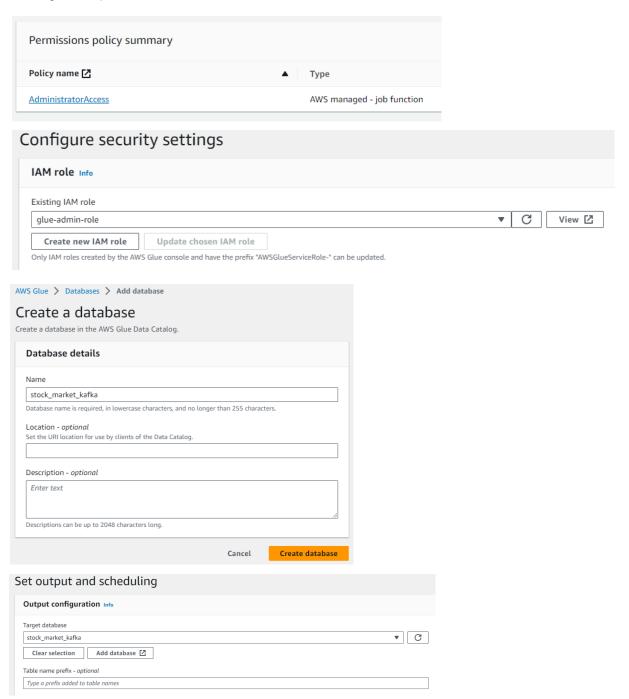
# Nos vamos al servicio AWS Glue y creamos un nuevo Crawler.



Debemos crear un nuevo rol para acceder desde Glue hacia los demás servicios sin problema.

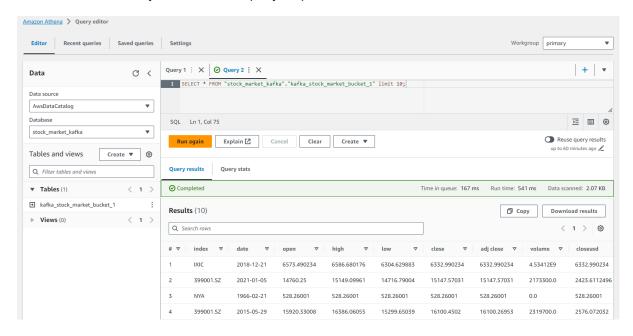


Le asignamos permisos de administrador.

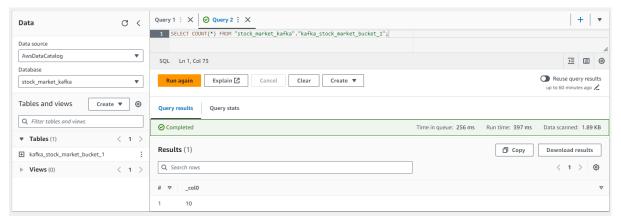


Finalmente creamos el crawler.

Ahora ingresamos a Amazon Athena y seleccionamos el Query editor. Elegimos la base de datos creada anteriormente y realizamos un query de prueba.



Por último, corremos nuevamente el producer y consumer con tiempo de espera de 5 segundos y validamos en Athena la cantidad de archivos json que hay en nuestro S3, con ayuda de un query.



Este valor va cambiando con el tiempo, por lo que se cumple el objetivo del laboratorio de manejar datos en tiempo real.